



Bone Fracture Detection

Matheus Nogueira
Nicolas Lamback
Nicolas Zamprogno
Vitor Vale



Apresentação do Problema


- Diagnóstico de fraturas é um problema comum na medicina
- Análise manual de radiografias pode ser lenta e sujeita a erros
- Visão computacional pode auxiliar na detecção automática de fraturas
- Objetivo: apoiar profissionais de saúde com diagnósticos mais rápidos e precisos






Descrição do Dataset

- Imagens de raio-X para detecção de fraturas ósseas
- Dividido em conjuntos de treino, validação e teste
- Gráficos mostram a distribuição de classes em cada conjunto
- Contém imagens com e sem anotações (background apenas)
- Anotações originais com em formato poligonal convertidas para retângulos (*bounding boxes*)


Exemplo das classes





Distribuição de Classes



Imagens anotadas x Não anotadas (background apenas)



Anotações em polígono x retângulo (*bounding box*)





Protocolo experimental - Comparação de três modelos

Modelo 1 — Parâmetros padrão

Treinado com as configurações padrão da biblioteca *Ultralytics*, utilizando 100 épocas e *early stopping* após 15 épocas sem melhoria.

Modelo 2 — Aplicação de *data augmentation* 1

Mantiveram-se as 100 épocas, porém foram aplicadas modificações no *learning rate* e nas transformações geométricas e de cor, com objetivo de aumentar a variabilidade das amostras de treino.


Modelo 3 — Aplicação de *data augmentation* 2

Foram utilizados 150 épocas de treinamento, *early stopping* de 50 épocas, e remoção das imagens sem anotações.

Arquitetura da Rede

Modelo escolhido: Yolo v11 Nano

- Baixo custo computacional para treinamento
- Menor necessidade de memória



Fonte: Documentação do Ultralytics (<https://docs.ultralytics.com/pt/compare/>)

Protocolo experimental

Modelo 1:

```
results = model.train(  
    data=data_yaml_path,  
    epochs=100,  
    batch=16,  
    imgsz=640,  
    patience=15,  
    save=True,  
    save_period=-1,  
    project="bone_yolo",  
    name="exp",  
    device=device
```


Modelo 2:

```
results = model.train(  
    data=yaml_path,  
    epochs=100,  
    batch=16,  
    imgsz=640,  
    patience=15,  
  
    lr=0.005,  
    lrf=0.01,  
    optimizer="auto",  
    weight_decay=0.0005,  
  
    mosaic=0.0,  
    mixup=0.0,  
    hsv_h=0.015,  
    hsv_s=0.7,  
    hsv_v=0.4,  
    erasing=0.0,  
  
    fliplr=0.5,  
    degrees=5.0,  
    translate=0.1,  
    scale=0.5,  
  
    plots=True,  
    verbose=True,  
    save=True,  
    save_period=-1,  
    project="bone_yolo",  
    name="exp",  
    device=device
```


Modelo 3:

```
results = model.train(  
    data=yaml_path,  
    epochs=150,  
    batch=16,  
    imgsz=640,  
    patience=50,  
  
    lr=0.01,  
    lrf=0.01,  
    optimizer="auto",  
    weight_decay=0.0005,  
  
    mosaic=0.0,  
    mixup=0.0,  
    hsv_h=0.0,  
    hsv_s=0.0,  
    fliplr=0.5,  
  
    hsv_v=0.4,  
    degrees=15.0,  
    translate=0.1,  
    scale=0.1,  
  
    plots=True,  
    verbose=True,  
    save=True,  
    resume=True,  
    project="bone_yolo",  
    name="exp_safe_params",  
    device=device
```

Convergência da rede - Incluindo imagens sem anotações



Convergência da rede - Excluindo imagens sem anotações



Análise de Resultados

Imagens com anotações


Class	Images	Instances	Box(P	R	mAP50	mAP50-95): 100%	11/11 0.3it/s 36.4s
all	169	96	0.352	0.229	0.219	0.091	
elbow positive	13	17	0	0	0.0268	0.0161	
fingers positive	22	27	0.288	0.148	0.175	0.0411	
forearm fracture	13	14	0.822	0.333	0.438	0.222	
humerus	14	15	0.451	0.385	0.306	0.139	
shoulder fracture	15	17	0.383	0.176	0.212	0.0732	
wrist positive	6	6	0.166	0.333	0.159	0.054	

Imagens sem anotações


Class	Images	Instances	Box(P	R	mAP50	mAP50-95): 100%	6/6 0.3it/s 22.0s
all	83	96	0.333	0.23	0.24	0.0925	
elbow positive	13	17	0.0606	0.0285	0.0284	0.00569	
fingers positive	22	27	0.397	0.222	0.17	0.0426	
forearm fracture	13	14	0.553	0.286	0.392	0.207	
humerus	14	15	0.462	0.333	0.357	0.134	
shoulder fracture	15	17	0.318	0.176	0.218	0.0739	
wrist positive	6	6	0.207	0.333	0.278	0.092	

Matriz de Confusão

Imagens com anotações:




Imagens sem anotações:




Exemplos de predição em imagens sem anotações

Acertos:




Erros:





Exemplos de predição em imagens com anotações

Acertos:



Erros:





Trabalhos Futuros

Imagens de raio-X, por si só, constituem um desafio devido à natureza do seu processo de aquisição e às características intrínsecas desse tipo de sinal. Para trabalhos futuros, recomenda-se a adoção de abordagens baseadas em *ensembles*, combinando diferentes técnicas por meio de, por exemplo, de *Weighted Box Fusion*. Além disso, de acordo com Wu et al. (2023), modelos baseados em propostas de regiões, como o Faster R-CNN, também podem apresentar bom desempenho.

J. Wu, X. Xu and J. Yang, "Object Detection and X-Ray Security Imaging: A Survey," in IEEE Access, vol. 11, pp. 45416-45441, 2023, doi: 10.1109/ACCESS.2023.3273736.



Conclusão

Mesmo com as imagens sem anotações, o modelo continua fazendo muitas previsões consideradas como “Falso Negativo” o que indica que essas imagens não estão influenciando o modelo a prever mais imagens como background.

A classe “*fingers positive*” tem a maior quantidade percentual de erros Falsos Positivos, o que indica que essas regiões das mãos, com ossos de formatos complexos têm maiores confusões com fraturas reais.

Nos dois casos os modelos apresentaram uma queda nas métricas de *loss* de treino que não foi correspondida pela queda de *loss* na validação, o que indica que o *data augmentation* não foi o suficiente para lidar com o *overfitting* dos modelo.



Obrigado!